ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ

MINH TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA TOÁN - ỨNG DỤNG

BÁO CÁO

TÍNH TOÁN THÔNG MINH

ĐỀ TÀI: Phân loại ảnh sử dụng tối ưu bầy đàn (PSO) trong lựa chọn đặc trưng (Image Classification with Particle Swarm Optimization (PSO)-based Feature Selection)

Giáo viên hướng dẫn: TS.Huỳnh Minh Trí

Nhóm thực hiện: Nhóm 15

TP. Hồ Chí Minh, Tháng 4, năm 2026

DANH SÁCH PHÂN CÔNG THÀNH VIÊN

Tên thành viên	MSSV	Đóng góp
Lê Phương Vy	3123580064	
Nguyễn Văn Hậu	3123580012	
Nguyễn Thị Minh Thùy	3123580049	
Đỗ Ngọc Như Ý	3123580067	
Tăng Vịnh Tuấn	3123580059	

LỜI MỞ ĐẦU

Trong lĩnh vực trí tuệ nhân tạo (Artificial Intelligence), bài toán phân tích và xử lý hình ảnh ngày càng được quan tâm nhờ khả năng ứng dụng rộng rãi trong nhiều lĩnh vực như nhận dạng khuôn mặt, phân tích cảm xúc và giám sát an ninh. Một trong những nhiệm vụ quan trọng của thị giác máy tính là phân loại ảnh (Image Classification), trong đó hệ thống cần gán nhãn cho hình ảnh dựa trên nội dung của chúng.

Trong quá trình xây dựng mô hình phân loại, việc trích xuất đặc trưng đóng vai trò quan trọng nhằm chuyển đổi dữ liệu ảnh thành dạng số. Trong đề tài này, phương pháp Local Binary Pattern (LBP) được sử dụng để trích xuất đặc trưng từ ảnh khuôn mặt. Tuy nhiên, số lượng đặc trưng thu được thường lớn và chứa nhiều thông tin dư thừa, làm ảnh hưởng đến hiệu quả của mô hình.

Do đó, việc lựa chọn đặc trưng là cần thiết nhằm giảm số chiều dữ liệu và cải thiện hiệu suất. Đề tài sử dụng thuật toán Particle Swarm Optimization (PSO) để lựa chọn tập đặc trưng tối ưu trước khi đưa vào mô hình phân loại Support Vector Machine (SVM).

Cách tiếp cận này giúp giảm các đặc trưng không cần thiết, đồng thời nâng cao hiệu quả và khả năng xử lý của hệ thống phân loại ảnh.

LỜI CẢM ƠN

Nhóm chúng em xin gửi lời cảm ơn chân thành và sâu sắc đến thầy *Huỳnh Minh Trí* – giảng viên phụ trách môn *Tính toán thông minh*, người đã tận tình giảng dạy và hướng dẫn nhóm trong suốt quá trình học tập và thực hiện bài báo cáo cuối kỳ.

Thông qua các buổi học lý thuyết kết hợp với thực hành, thầy đã giúp chúng em từng bước tiếp cận và hiểu rõ các phương pháp trong lĩnh vực tính toán thông minh. Đặc biệt, việc tìm hiểu và áp dụng các thuật toán tối ưu hóa như Particle Swarm Optimization (PSO) đã giúp nhóm hiểu rõ hơn cách các thuật toán lấy cảm hứng từ tự nhiên có thể được sử dụng để tìm kiếm lời giải tối ưu cho các bài toán thực tế.

Nhờ phương pháp giảng dạy khoa học, dễ hiểu cùng với các ví dụ minh họa cụ thể, nhóm không chỉ củng cố kiến thức lý thuyết mà còn nâng cao kỹ năng lập trình, tư duy tối ưu hóa và khả năng áp dụng các thuật toán vào việc giải quyết các bài toán thực tế.

Mặc dù nhóm đã cố gắng hoàn thiện bài báo cáo cuối kỳ trong phạm vi kiến thức và thời gian cho phép, song không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ thầy để có thể rút kinh nghiệm và hoàn thiện hơn trong quá trình học tập và nghiên cứu sau này.

Nhóm chúng em xin trân trọng cảm ơn thầy!

MỤC LỤC

Danh sách hình vẽ.....7
Chương I: Giới thiệu.....1
1. Tổng quan đề tài.....1
2. Tình hình nghiên cứu.....2
3. Mục tiêu và câu hỏi nghiên cứu.....2
4. Đóng góp của đề tài.....3
5. Phương pháp và phạm vi nghiên cứu.....3
6. Hướng tiếp cận và cấu trúc báo cáo.....4
Chương 2: Cơ sở lý thuyết.....4
1. Tổng quan bài toán phân loại ảnh.....4
2. Trích xuất đặc trưng bằng Local Binary Pattern (LBP).....5
3. Mô hình phân loại Support Vector Machine (SVM).....6
4. Thuật toán Particle Swarm Optimization (PSO).....7
4.1. Khái niệm.....7
4.2. Cơ chế hoạt động.....7
4.3. Ứng dụng PSO trong lựa chọn đặc trưng.....7
5. Quy trình kết hợp LBP – PSO – SVM trong bài toán.....8
6. Phương pháp đánh giá mô hình.....8
Chương 3: Dữ liệu và phương pháp nghiên cứu.....9
1. Tổng quan quy trình.....9
2. Mô tả và xử lý dữ liệu.....9
2.1. Đặc điểm dữ liệu đầu vào.....9
2.2. Gán nhãn cảm xúc tự động.....10
2.3. Phân tích và cân bằng dữ liệu.....11
3. Trích xuất và biểu diễn đặc trưng ảnh.....11
3.1. Tiền xử lý dữ liệu ảnh.....11
3.2. Phương pháp Cell-based LBP.....12
3.3. Xây dựng và biểu diễn tập dữ liệu đặc trưng.....13
4. Tối ưu đặc trưng bằng PSO.....14
4.1. Động cơ lựa chọn PSO.....14

4.2. Biểu diễn cá thể và hàm mục tiêu tối ưu 14
4.3. Cấu hình và thực thi thuật toán 15
5. Chuẩn bị dữ liệu và thiết lập mô hình phân loại SVM 16
5.1. Mã hóa nhãn dữ liệu 16
5.2. Chia tập dữ liệu huấn luyện và kiểm tra 17
5.3. Chuẩn bị dữ liệu sau tối ưu đặc trưng 17
5.4. Thiết lập mô hình phân loại SVM 18
6. Kết luận chương 19
Chương 4: Thảo luận kết quả thực nghiệm 20
1. Kết quả trước khi áp dụng PSO 20
2. Kết quả sau khi áp dụng PSO 21
2.1. Phân tích hiệu quả giảm chiều dữ liệu 21
2.2. Kết quả phân loại sau PSO 22
2.3. Phân tích ma trận nhầm lẫn (Confusion Matrix) 24
2.4. Phân tích quá trình hội tụ của PSO 25
2.5. Phân tích đặc trưng được lựa chọn 26
2.6. Phân bố dữ liệu các lớp 28
3. So sánh trước và sau khi áp dụng PSO 29
4. Đánh giá tổng thể 30
5. Kết luận chương 31
Chương 5: Tổng kết 32
1. Kết luận 32
2. Hạn chế của đề tài 32
3. Hướng phát triển 33
Tài liệu tham khảo 35

Danh sách hình vẽ

1. *Sơ đồ pipeline* 9
2. *Feature Reduction - Biểu đồ so sánh số lượng đặc trưng.* 22
3. *Confusion Matrix - Ma trận nhầm lẫn.* 24
4. *Fitness Convergence - Biểu đồ lịch sử hội tụ.* 25
5. *Biểu đồ các đặc trưng được PSO lựa chọn.* 26
6. *Class Distribution - Biểu đồ hình tròn phân bổ nhãn.* 28
7. *Biểu đồ So sánh Trước và Sau khi tối ưu hóa bằng PSO.* 29

Chương I: Giới thiệu

1. Tổng quan đề tài

Phân loại ảnh (Image Classification) là một bài toán quan trọng trong lĩnh vực thị giác máy tính (Computer Vision), với mục tiêu gán nhãn cho hình ảnh dựa trên nội dung trực quan của chúng. Trong những năm gần đây, cùng với sự phát triển mạnh mẽ của trí tuệ nhân tạo, bài toán này ngày càng được ứng dụng rộng rãi trong nhiều lĩnh vực như nhận dạng khuôn mặt, phân tích cảm xúc, y tế, giám sát an ninh và thương mại điện tử, đóng vai trò quan trọng trong các hệ thống thông minh hiện đại.

Trong quá trình xây dựng mô hình phân loại ảnh, việc trích xuất đặc trưng từ dữ liệu ảnh là bước quan trọng nhằm biểu diễn thông tin ảnh dưới dạng số để các thuật toán học máy có thể xử lý. Tuy nhiên, số lượng đặc trưng thu được thường lớn và không phải tất cả đều mang ý nghĩa phân biệt. Việc sử dụng quá nhiều đặc trưng có thể dẫn đến hiện tượng dư thừa dữ liệu, làm giảm hiệu quả mô hình và gia tăng chi phí tính toán.

Trong nghiên cứu này, phương pháp Local Binary Pattern (LBP) được sử dụng để trích xuất đặc trưng từ ảnh khuôn mặt. Đây là một phương pháp hiệu quả trong việc mô tả đặc trưng kết cấu (texture), đặc biệt phù hợp với các bài toán nhận dạng và phân tích biểu cảm khuôn mặt. LBP được đề xuất bởi Ojala et al. (2002) và đã chứng minh hiệu quả trong nhiều nghiên cứu nhờ khả năng mô tả đặc trưng cục bộ một cách đơn giản nhưng mạnh mẽ.

Bên cạnh đó, lựa chọn đặc trưng (Feature Selection) là một bước cần thiết nhằm giữ lại các đặc trưng quan trọng và loại bỏ các đặc trưng không cần thiết. Trong số các phương pháp tối ưu hóa, Particle Swarm Optimization (PSO) là một thuật toán hiệu quả nhờ cấu trúc đơn giản, số lượng tham số ít và khả năng hội tụ nhanh trong không gian tìm kiếm lớn.

Tuy nhiên, việc xác định tập đặc trưng tối ưu vẫn là một thách thức do không gian tìm kiếm rộng và độ phức tạp cao. Xuất phát từ vấn đề này, đề tài "*Image Classification with Particle Swarm Optimization (PSO) based Feature Selection*" được thực hiện nhằm nâng cao hiệu quả của mô hình phân loại ảnh thông qua việc tối ưu hóa tập đặc trưng.

2. Tình hình nghiên cứu

Bài toán phân loại ảnh đã được nghiên cứu rộng rãi với nhiều hướng tiếp cận khác nhau nhằm nâng cao độ chính xác và hiệu suất hệ thống. Các phương pháp trích xuất đặc trưng truyền thống như Histogram, Histogram of Oriented Gradients (HOG) và Local Binary Pattern (LBP) đã được sử dụng phổ biến trong các bài toán nhận dạng và phân tích ảnh.

Song song đó, nhiều nghiên cứu tập trung vào việc giảm số chiều dữ liệu thông qua các phương pháp lựa chọn đặc trưng như Filter methods, Wrapper methods và Embedded methods. Gần đây, các thuật toán tối ưu hóa như Genetic Algorithm (GA), Particle Swarm Optimization (PSO) và Ant Colony Optimization (ACO) được áp dụng nhằm cải thiện hiệu quả của quá trình lựa chọn đặc trưng.

Trong số đó, PSO được đánh giá là một phương pháp hiệu quả nhờ khả năng tìm kiếm nghiệm tối ưu nhanh và dễ triển khai. Theo Kennedy và Eberhart (1995), PSO là một thuật toán tối ưu hóa dựa trên hành vi bầy đàn, có khả năng tìm kiếm nghiệm tối ưu hiệu quả trong không gian lớn.

Ngoài ra, Support Vector Machine (SVM) do Cortes và Vapnik (1995) đề xuất là một trong những mô hình phân loại mạnh mẽ, đặc biệt hiệu quả trong không gian đặc trưng có số chiều cao.

Tuy nhiên, phần lớn các nghiên cứu hiện nay tập trung vào việc cải thiện mô hình phân loại hoặc sử dụng các phương pháp học sâu, trong khi việc kết hợp hiệu quả giữa trích xuất đặc trưng truyền thống và tối ưu hóa lựa chọn đặc trưng vẫn chưa được khai thác đầy đủ, đặc biệt trong bối cảnh dữ liệu hạn chế và tài nguyên tính toán không cao. Đây chính là khoảng trống nghiên cứu mà đề tài hướng đến.

3. Mục tiêu và câu hỏi nghiên cứu

Mục tiêu chính của đề tài là nghiên cứu và áp dụng thuật toán Particle Swarm Optimization (PSO) để lựa chọn tập đặc trưng tối ưu cho bài toán phân loại cảm xúc khuôn mặt, từ đó nâng cao hiệu quả của hệ thống phân loại.

Cụ thể, đề tài hướng đến các mục tiêu sau:

- Trích xuất đặc trưng từ ảnh khuôn mặt bằng phương pháp Local Binary Pattern (LBP)
- Áp dụng thuật toán PSO để lựa chọn tập đặc trưng tối ưu
- Xây dựng mô hình phân loại sử dụng Support Vector Machine (SVM)
- Đánh giá và so sánh hiệu quả của mô hình trước và sau khi áp dụng PSO

Từ đó, nghiên cứu đặt ra các câu hỏi:

- Việc áp dụng PSO có giúp cải thiện hiệu quả phân loại hay không?
- PSO có thể giảm số lượng đặc trưng mà vẫn đảm bảo độ chính xác không?
- Tập đặc trưng được lựa chọn ảnh hưởng như thế nào đến hiệu suất mô hình?

4. Đóng góp của đề tài

Đề tài có một số đóng góp chính như sau:

- Áp dụng phương pháp Local Binary Pattern (LBP) để trích xuất đặc trưng từ ảnh khuôn mặt phục vụ bài toán phân loại cảm xúc.
- Kết hợp thuật toán PSO để thực hiện lựa chọn đặc trưng nhằm giảm số chiều dữ liệu.
- Xây dựng mô hình phân loại ảnh sử dụng thuật toán SVM.
- Thực nghiệm và đánh giá hiệu quả của phương pháp thông qua việc so sánh kết quả trước và sau khi áp dụng PSO.

5. Phương pháp và phạm vi nghiên cứu

Đề tài sử dụng các phương pháp trong lĩnh vực học máy và tối ưu hóa. Quy trình nghiên cứu bao gồm các bước chính: tiền xử lý dữ liệu ảnh, trích xuất đặc trưng bằng LBP, lựa chọn đặc trưng bằng PSO và phân loại bằng SVM.

Hiệu quả của mô hình được đánh giá thông qua các chỉ số như Accuracy và Confusion Matrix. Trong phạm vi nghiên cứu, đề tài tập trung vào các phương pháp truyền thống

(LBP, SVM) kết hợp với thuật toán tối ưu PSO, không đi sâu vào các mô hình học sâu do hạn chế về tài nguyên và thời gian.

6. Hướng tiếp cận và cấu trúc báo cáo

Đề tài được tiếp cận theo hướng kết hợp giữa trích xuất đặc trưng, lựa chọn đặc trưng và mô hình phân loại nhằm xây dựng hệ thống phân loại ảnh hiệu quả. Việc sử dụng PSO giúp giảm số lượng đặc trưng không cần thiết, từ đó cải thiện hiệu suất tính toán và khả năng tổng quát hóa của mô hình.

Báo cáo được tổ chức thành các chương:

- Chương 1: Giới thiệu
- Chương 2: Cơ sở lý thuyết
- Chương 3: Dữ liệu và phương pháp nghiên cứu
- Chương 4: Thảo luận kết quả thực nghiệm
- Chương 5: Tổng kết

Chương 2: Cơ sở lý thuyết

1. Tổng quan bài toán phân loại ảnh

Phân loại ảnh (Image Classification) là một trong những bài toán cơ bản và quan trọng trong lĩnh vực thị giác máy tính (Computer Vision). Mục tiêu của bài toán là xây dựng một hệ thống có khả năng tự động gán nhãn cho hình ảnh dựa trên nội dung trực quan của chúng. Dữ liệu đầu vào của hệ thống là các hình ảnh, trong khi đầu ra là các nhãn thuộc những lớp đã được xác định trước.

Trong thực tế, bài toán phân loại ảnh được ứng dụng rộng rãi trong nhiều lĩnh vực như nhận dạng khuôn mặt, phân tích cảm xúc, chẩn đoán y khoa, giám sát an ninh và thương mại điện tử. Tuy nhiên, do dữ liệu ảnh thường có kích thước lớn và chứa nhiều thông tin phức tạp, việc xử lý trực tiếp trên dữ liệu thô là không hiệu quả. Do đó, cần phải chuyển đổi dữ liệu ảnh sang dạng đặc trưng phù hợp trước khi đưa vào mô hình học máy.

Một hệ thống phân loại ảnh điển hình bao gồm các bước chính sau:

- Tiền xử lý dữ liệu: chuẩn hóa kích thước ảnh, chuyển đổi màu sắc, loại bỏ nhiễu

- Trích xuất đặc trưng: chuyển đổi ảnh thành vector đặc trưng
- Lựa chọn đặc trưng: loại bỏ các đặc trưng dư thừa
- Huấn luyện mô hình: xây dựng mô hình học máy
- Đánh giá: đo lường hiệu quả bằng các chỉ số

Trong phạm vi đề tài, bài toán được áp dụng cho phân loại cảm xúc khuôn mặt, trong đó mỗi ảnh khuôn mặt sẽ được gán một nhãn cảm xúc tương ứng.

2. Trích xuất đặc trưng bằng Local Binary Pattern (LBP)

Local Binary Pattern (LBP) là một phương pháp trích xuất đặc trưng dựa trên kết cấu (texture) của ảnh, được sử dụng rộng rãi trong các bài toán nhận dạng khuôn mặt.

Ý tưởng chính của LBP là so sánh giá trị của một pixel trung tâm với các pixel lân cận xung quanh. Kết quả so sánh được biểu diễn dưới dạng chuỗi nhị phân, sau đó chuyển thành giá trị thập phân để mô tả đặc trưng cục bộ của ảnh.

Công thức LBP

$$LBP = \sum_{p=0}^{P-1} s(g_p - g_c) \cdot 2^p$$

Trong đó:

- g_c: giá trị pixel trung tâm
- g_p: giá trị pixel lân cận

Hàm $s(x)$:

$$s(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

LBP thường được ký hiệu là LBP(P, R):

- P: số điểm lân cận
- R: bán kính

Sau khi tính toán cho toàn bộ ảnh, các giá trị LBP được tổng hợp thành histogram để tạo thành vector đặc trưng đại diện cho ảnh.

LBP có các ưu điểm:

- Tính toán đơn giản, tốc độ nhanh
- Hiệu quả cao trong bài toán khuôn mặt

- Ít bị ảnh hưởng bởi thay đổi ánh sáng

Trong đề tài, vector đặc trưng LBP được sử dụng làm đầu vào cho bước lựa chọn đặc trưng bằng PSO và mô hình phân loại SVM. Trong quá trình thực nghiệm, mỗi vector LBP sẽ được đưa vào thuật toán PSO để tìm ra tập đặc trưng tối ưu trước khi thực hiện phân loại.

Tuy nhiên, LBP cũng tồn tại một số hạn chế, chẳng hạn như nhạy cảm với nhiễu và không nắm bắt được thông tin cấu trúc toàn cục của ảnh, do đó thường cần kết hợp với các phương pháp khác để nâng cao hiệu quả.

3. Mô hình phân loại Support Vector Machine (SVM)

Support Vector Machine (SVM) là một thuật toán học máy có giám sát, được sử dụng phổ biến trong các bài toán phân loại. Mục tiêu của SVM là tìm một siêu phẳng tối ưu để phân tách các lớp dữ liệu sao cho khoảng cách giữa các lớp là lớn nhất.

Công thức tối ưu hóa

$$\min_{w,b} \frac{1}{2} \| w \|^2 \text{ s.t. } y_i(w \cdot x_i + b) \geq 1$$

Trong đó:

- w: vector trọng số
- b: hệ số bias
- x_i: dữ liệu đầu vào
- y_i: nhãn

Đối với dữ liệu không phân tách tuyến tính, SVM sử dụng hàm kernel để ánh xạ dữ liệu sang không gian có chiều cao hơn. Trong đề tài, kernel RBF (Radial Basis Function) được sử dụng do khả năng xử lý tốt các dữ liệu phi tuyến. Kernel RBF cho phép ánh xạ dữ liệu vào không gian có chiều cao hơn, từ đó giúp mô hình phân tách các lớp không tuyến tính. Điều này đặc biệt phù hợp với đặc trưng LBP, vốn không đảm bảo tính phân tách tuyến tính trong không gian ban đầu.

SVM được lựa chọn vì:

- Hiệu quả với dữ liệu nhiều chiều
- Khả năng tổng quát hóa tốt
- Hoạt động ổn định trong thực tế

4. Thuật toán Particle Swarm Optimization (PSO)

4.1. Khái niệm

Particle Swarm Optimization (PSO) là một thuật toán tối ưu hóa dựa trên quần thể, mô phỏng hành vi di chuyển của đàn chim hoặc đàn cá trong tự nhiên. Mỗi cá thể (particle) đại diện cho một nghiệm trong không gian tìm kiếm.

4.2. Cơ chế hoạt động

Mỗi particle có:

- Vị trí x_i: biểu diễn nghiệm
- Vận tốc v_i: biểu diễn hướng di chuyển

Các particle di chuyển trong không gian tìm kiếm dựa trên:

- Kinh nghiệm cá nhân (pbest)
- Kinh nghiệm toàn cục (gbest)

Công thức cập nhật

$$v_i = wv_i + c_1r_1(pbest_i - x_i) + c_2r_2(gbest - x_i)$$

$$x_i = x_i + v_i$$

Cơ chế này giúp các particle dần hội tụ về nghiệm tối ưu thông qua việc kết hợp giữa khai thác kinh nghiệm tốt nhất và khám phá không gian tìm kiếm.

4.3. Ứng dụng PSO trong lựa chọn đặc trưng

Trong đề tài, PSO được sử dụng để lựa chọn tập đặc trưng tối ưu từ vector đặc trưng LBP.

Mỗi particle được biểu diễn dưới dạng vector nhị phân:

- 1: chọn đặc trưng
- 0: loại bỏ đặc trưng

Hàm mục tiêu

$$Fitness = \alpha \cdot Accuracy + (1 - \alpha) \cdot \left(1 - \frac{\text{Selected Features}}{\text{Total Features}}\right)$$

Hàm mục tiêu này đảm bảo sự cân bằng giữa việc tối đa hóa độ chính xác và tối thiểu hóa số lượng đặc trưng, giúp mô hình vừa hiệu quả vừa gọn nhẹ.

Hàm mục tiêu giúp cân bằng giữa:

- Độ chính xác của mô hình

- Số lượng đặc trưng được chọn

Tuy nhiên, PSO cũng có thể gặp phải hiện tượng hội tụ sớm vào nghiệm cục bộ (local optimum), đặc biệt khi không gian tìm kiếm quá lớn hoặc cấu hình tham số chưa phù hợp.

5. Quy trình kết hợp LBP – PSO – SVM trong bài toán

Trong đề tài, ba thành phần LBP, PSO và SVM được kết hợp thành một quy trình hoàn chỉnh để giải quyết bài toán phân loại ảnh.

Quy trình thực hiện gồm các bước:

1. Tiền xử lý ảnh: chuẩn hóa kích thước, chuyển ảnh về dạng grayscale
2. Trích xuất đặc trưng: sử dụng LBP để chuyển ảnh thành vector đặc trưng
3. Lựa chọn đặc trưng: áp dụng PSO để chọn ra tập đặc trưng tối ưu
4. Huấn luyện mô hình: sử dụng SVM với kernel RBF
5. Đánh giá mô hình: sử dụng các chỉ số đánh giá

Trong đó:

- LBP đóng vai trò biểu diễn dữ liệu
- PSO tối ưu hóa tập đặc trưng
- SVM thực hiện phân loại

Sự kết hợp này giúp giảm số lượng đặc trưng dư thừa, cải thiện hiệu suất và tăng khả năng phân loại của hệ thống.

Quy trình này không chỉ giúp giảm số chiều dữ liệu mà còn góp phần nâng cao độ chính xác và giảm chi phí tính toán của mô hình phân loại.

6. Phương pháp đánh giá mô hình

Để đánh giá hiệu quả của mô hình, đề tài sử dụng các chỉ số:

- Accuracy: tỷ lệ dự đoán đúng trên tổng số mẫu
- Confusion Matrix: thể hiện chi tiết kết quả phân loại theo từng lớp

Các chỉ số này được sử dụng để so sánh hiệu quả của mô hình trước và sau khi áp dụng PSO, từ đó đánh giá vai trò của việc lựa chọn đặc trưng.

Kết luận chương 2:

Chương này đã trình bày các cơ sở lý thuyết quan trọng bao gồm phương pháp trích xuất đặc trưng Local Binary Pattern (LBP), mô hình phân loại Support Vector Machine

(SVM) và thuật toán tối ưu Particle Swarm Optimization (PSO). Đồng thời, chương cũng đã làm rõ quy trình kết hợp các phương pháp này trong bài toán phân loại ảnh.

Việc kết hợp LBP, PSO và SVM tạo thành một pipeline hoàn chỉnh từ trích xuất đặc trưng đến tối ưu hóa và phân loại, giúp nâng cao hiệu quả của hệ thống phân loại ảnh. Đây là nền tảng cho phần thực nghiệm và đánh giá trong các chương tiếp theo.

Chương 3: Dữ liệu và phương pháp nghiên cứu

1. Tổng quan quy trình

Quy trình nghiên cứu được xây dựng theo hướng thực nghiệm, tập trung vào xử lý dữ liệu ảnh và tối ưu hóa đặc trưng nhằm phục vụ bài toán phân loại cảm xúc khuôn mặt. Pipeline bao gồm các bước chính: thu thập dữ liệu ảnh thô, gán nhãn cảm xúc tự động, phân tích và cân bằng dữ liệu, trích xuất đặc trưng bằng phương pháp Cell-based LBP, tối ưu đặc trưng bằng thuật toán PSO, và cuối cùng là chuẩn bị dữ liệu cho mô hình phân loại SVM.

Khác với các nghiên cứu sử dụng dữ liệu đã được gán nhãn sẵn, bài toán này bắt đầu từ dữ liệu chưa có nhãn. Do đó, bước gán nhãn tự động đóng vai trò quan trọng, ảnh hưởng trực tiếp đến chất lượng của toàn bộ quá trình học. Bên cạnh đó, việc kết hợp giữa đặc trưng thủ công (LBP) và thuật toán tối ưu (PSO) giúp cải thiện khả năng biểu diễn dữ liệu trước khi đưa vào mô hình học máy.

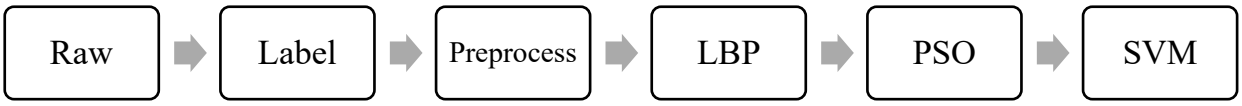

Hình 1. Sơ đồ pipeline

Kết quả của quy trình là một tập dữ liệu đặc trưng đã được tối ưu, sẵn sàng cho việc huấn luyện và đánh giá mô hình ở chương tiếp theo.

2. Mô tả và xử lý dữ liệu

2.1. Đặc điểm dữ liệu đầu vào

Dữ liệu ban đầu bao gồm các ảnh khuôn mặt được lưu trữ trong thư mục data/raw. Các ảnh này có các đặc điểm sau:

- Không có nhãn cảm xúc (unlabeled)
- Kích thước và độ phân giải không đồng nhất
- Có thể chứa nhiễu như ánh sáng kém, góc chụp lệch hoặc nền phức tạp

Việc thiếu nhãn khiến bài toán không thể áp dụng trực tiếp các phương pháp học có giám sát, do đó cần một bước trung gian để xây dựng nhãn dữ liệu.

2.2. Gán nhãn cảm xúc tự động

Để giải quyết vấn đề thiếu nhãn, hệ thống sử dụng thư viện DeepFace để phân tích và gán nhãn cảm xúc cho từng ảnh khuôn mặt.

[Input]

```python
# Chạy gán nhãn (thử nghiệm với 500 ảnh đầu tiên để kiểm tra tốc độ)
sample_size = 5000
for img_path in tqdm(all_image_paths[:sample_size]):
    try:
        # Sử dụng backend 'opencv' để tốc độ quét nhanh nhất
        results = DeepFace.analyze(img_path=img_path, actions=['emotion'],
                                   enforce_detection=True, detector_backend='opencv')
        emotion = results[0]['dominant_emotion']

        target_dir = os.path.join(output_root, emotion)
        os.makedirs(target_dir, exist_ok=True)
        shutil.copy(img_path, os.path.join(target_dir, os.path.basename(img_path)))
    except:
        continue
```

```python
import os

path_labeled = "/content/drive/MyDrive/TTTM-2026-DR/data/labeled"

if os.path.exists(path_labeled):
    emotions = os.listdir(path_labeled)
    print(f"Tìm thấy các nhãn cảm xúc: {emotions}")
    for emotion in emotions:
        count = len(os.listdir(os.path.join(path_labeled, emotion)))
        print(f" - Cảm xúc '{emotion}': {count} ảnh")
else:
    print("Thư mục không tồn tại")
```

[Output]

```
  0%|          | 0/5000 [00:00<?, ?it/s]Downloading...
From: https://github.com/serengil/deepface_models/releases/downl
To: /root/.deepface/weights/facial_expression_model_weights.h5
26-03-14 08:08:40 - 🔗 facial_expression_model_weights.h5 will

100%|██████████| 5.98M/5.98M [00:00<00:00, 219MB/s]
100%|██████████| 5000/5000 [31:46<00:00,  2.62it/s]

Tìm thấy các nhãn cảm xúc: ['angry', 'sad', 'happy', 'neutral', 'disgust', 'fear', 'surprise']
 - Cảm xúc 'angry': 1049 ảnh
 - Cảm xúc 'sad': 1714 ảnh
 - Cảm xúc 'happy': 3311 ảnh
 - Cảm xúc 'neutral': 2384 ảnh
 - Cảm xúc 'disgust': 92 ảnh
 - Cảm xúc 'fear': 995 ảnh
 - Cảm xúc 'surprise': 230 ảnh
```

Với 5000 ảnh đầu vào, hệ thống sử dụng hàm phân tích để xác định cảm xúc chủ đạo của khuôn mặt. Cấu hình cụ thể:

- Chỉ thực hiện nhận diện cảm xúc (emotion)
- Sử dụng backend OpenCV để tăng tốc độ xử lý
- Bỏ qua các ảnh không phát hiện được khuôn mặt

Quá trình này giúp chuyển đổi dữ liệu từ dạng chưa có nhãn sang dạng có thể sử dụng cho học có giám sát, đồng thời tổ chức dữ liệu theo từng lớp cảm xúc.

Kết quả cho thấy dữ liệu bị mất cân bằng rõ rệt giữa các lớp. Các cảm xúc như *happy* và *neutral* chiếm ưu thế, trong khi *disgust* và *surprise* có rất ít mẫu. Ngoài ra, do nhãn được sinh tự động, dữ liệu có thể chứa sai số do ảnh hưởng của điều kiện chụp hoặc chất lượng ảnh.

Mặc dù tồn tại nhiễu, phương pháp này vẫn đảm bảo tính khả thi trong bối cảnh không có dữ liệu gán nhãn thủ công. Tuy nhiên, việc sử dụng mô hình huấn luyện sẵn có thể dẫn đến sai lệch miền dữ liệu (domain mismatch), ảnh hưởng đến độ chính xác của nhãn.

2.3. Phân tích và cân bằng dữ liệu

Sau khi gán nhãn, tập dữ liệu xuất hiện sự mất cân bằng rõ rệt giữa các lớp cảm xúc. Cụ thể, các lớp như *happy* và *neutral* có số lượng ảnh lớn, trong khi *disgust* và *surprise* có rất ít mẫu. Sự chênh lệch này có thể khiến mô hình học thiên lệch, ưu tiên dự đoán các lớp chiếm ưu thế và làm giảm hiệu quả phân loại tổng thể.

Để khắc phục, nghiên cứu áp dụng phương pháp undersampling nhằm cân bằng dữ liệu giữa các lớp. Cụ thể, mỗi lớp được chọn tối đa 90 ảnh, tạo ra tập dữ liệu mới gồm 630 ảnh (7 lớp × 90 ảnh). Tập dữ liệu này được sử dụng cho các bước trích xuất đặc trưng và huấn luyện mô hình.

Việc cân bằng dữ liệu giúp mô hình học đồng đều hơn giữa các lớp, giảm hiện tượng thiên lệch và rút ngắn thời gian xử lý. Tuy nhiên, phương pháp này làm mất đi một phần dữ liệu ở các lớp lớn, dẫn đến giảm độ đa dạng của tập dữ liệu. Đây là sự đánh đổi giữa việc đảm bảo tính công bằng giữa các lớp và việc giữ lại đầy đủ thông tin ban đầu.

Trong phạm vi nghiên cứu, việc ưu tiên dữ liệu cân bằng được xem là phù hợp nhằm nâng cao hiệu quả phân loại đa lớp cảm xúc. Từ tập dữ liệu này, nghiên cứu tiếp tục thực hiện trích xuất đặc trưng để biểu diễn dữ liệu dưới dạng số phục vụ cho mô hình học máy.

3. Trích xuất và biểu diễn đặc trưng ảnh

3.1. Tiền xử lý dữ liệu ảnh

Trước khi tiến hành trích xuất đặc trưng, toàn bộ ảnh đầu vào được thực hiện các bước tiền xử lý nhằm chuẩn hóa dữ liệu và giảm chi phí tính toán:

- Chuyển ảnh từ không gian màu RGB sang ảnh xám (grayscale)
- Thay đổi kích thước ảnh về 64×64 pixel

```
def extract_cell_lbp(image_path):
    img = cv2.imread(image_path, cv2.IMREAD_GRAYSCALE)
    if img is None: return None
    img = cv2.resize(img, (64, 64))
```

Quá trình này giảm kích thước ảnh giúp:

- Giảm số lượng điểm ảnh cần xử lý

- Tăng tốc độ tính toán trong các bước tiếp theo
- Đảm bảo dữ liệu đồng nhất

Trong khi đó, ảnh xám vẫn giữ được các thông tin quan trọng về cấu trúc khuôn mặt như đường nét, biên và độ tương phản – là những yếu tố chính phục vụ cho nhận diện cảm xúc. Tuy nhiên, việc loại bỏ thông tin màu sắc có thể làm mất đi một phần tín hiệu liên quan đến cảm xúc (ví dụ: sắc thái da), dù ảnh hưởng này không đáng kể trong bài toán này.

3.2. Phương pháp Cell-based LBP

Sau bước tiền xử lý, nghiên cứu áp dụng phương pháp Local Binary Pattern (LBP) để trích xuất đặc trưng ảnh. Cụ thể, mỗi ảnh được chia thành 16 ô nhỏ (4×4), đặc trưng LBP được tính riêng cho từng ô và sau đó được ghép lại thành một vector đặc trưng hoàn chỉnh.

Phương pháp này, gọi là Cell-based LBP, cho phép mô tả không chỉ đặc trưng tổng thể mà còn cả thông tin cục bộ trên khuôn mặt.

```
for i in range(4):
    for j in range(4):
        # Cắt lấy một ô nhỏ
        cell = img[i*cell_h:(i+1)*cell_h, j*cell_w:(j+1)*cell_w]

        # Trích LBP cho ô đó
        lbp = local_binary_pattern(cell, n_points, radius, method='uniform')
        (hist, _) = np.histogram(lbp.ravel(), bins=np.arange(0, n_points + 3), range=(0, n_points + 2))
        hist = hist.astype("float")
        hist /= (hist.sum() + 1e-7)
        all_features.extend(hist)

return np.array(all_features)
```

Cách tiếp cận này mang lại một số ưu điểm nổi bật:

- Giúp nắm bắt hiệu quả các đặc trưng cục bộ như vùng mắt, miệng và chân mày – những khu vực thể hiện rõ cảm xúc
- Tăng khả năng phân biệt giữa các biểu cảm có đặc trưng tương đồng
- Phù hợp với bài toán nhận diện cảm xúc, vốn phụ thuộc nhiều vào sự thay đổi ở từng vùng trên khuôn mặt

3.3. Xây dựng và biểu diễn tập dữ liệu đặc trưng

[Input]

```
# Chạy lại trích xuất cho 630 tấm (90 tấm mỗi loại)
path_labeled = "/content/drive/MyDrive/TTTM-2026-DR/data/labeled"
X_new, y_new = [], []
for emotion in os.listdir(path_labeled):
    emotion_dir = os.path.join(path_labeled, emotion)
    if not os.path.isdir(emotion_dir): continue
    img_list = os.listdir(emotion_dir)[:90]
    for img_name in tqdm(img_list, desc=f"Trích xuất {emotion}"):
        feat = extract_cell_lbp(os.path.join(emotion_dir, img_name))
        if feat is not None:
            X_new.append(feat)
            y_new.append(emotion)

X = np.array(X_new)
y = np.array(y_new)
print(f"\nMa trận đặc trưng mới: {X.shape}")
```

[Output]

```
Trích xuất angry: 100%|██████████| 90/90 [00:24<00:00,  3.72it/s]
Trích xuất sad: 100%|██████████| 90/90 [00:55<00:00,  1.61it/s]
Trích xuất happy: 100%|██████████| 90/90 [01:19<00:00,  1.13it/s]
Trích xuất neutral: 100%|██████████| 90/90 [00:59<00:00,  1.51it/s]
Trích xuất disgust: 100%|██████████| 90/90 [00:56<00:00,  1.60it/s]
Trích xuất fear: 100%|██████████| 90/90 [00:21<00:00,  4.28it/s]
Trích xuất surprise: 100%|██████████| 90/90 [00:06<00:00, 14.30it/s]Ma trận đặc trưng mới: (630, 416)
```

Trong đó:

- 630 là số lượng ảnh sau khi cân bằng dữ liệu
- 416 là số lượng đặc trưng được trích xuất từ mỗi ảnh

Kích thước ma trận cho thấy mỗi ảnh được biểu diễn bởi một vector có số chiều tương đối lớn so với số lượng mẫu. Điều này dẫn đến một số vấn đề quan trọng:

- Xuất hiện hiện tượng *"curse of dimensionality"*, khi số chiều dữ liệu cao làm cho khoảng cách giữa các điểm trở nên kém ý nghĩa, từ đó ảnh hưởng đến hiệu quả phân loại
- Dữ liệu dễ bị nhiễu do không phải tất cả các đặc trưng đều quan trọng, một số đặc trưng có thể dư thừa hoặc gây ảnh hưởng tiêu cực đến mô hình
- Chi phí tính toán tăng cao do số chiều lớn, làm tăng thời gian huấn luyện và dự đoán

Những hạn chế trên cho thấy việc sử dụng toàn bộ 416 đặc trưng chưa chắc mang lại hiệu quả tối ưu. Do đó, cần có một phương pháp lựa chọn và tối ưu đặc trưng nhằm giảm chiều dữ liệu và cải thiện hiệu suất mô hình.

Trên cơ sở đó, nghiên cứu tiếp tục áp dụng thuật toán PSO trong bước tiếp theo để lựa chọn tập đặc trưng quan trọng.

Ngoài ra, số chiều đặc trưng lớn còn làm tăng nguy cơ quá khớp (overfitting), đặc biệt đối với các mô hình như SVM khi số lượng mẫu không đủ lớn. Điều này có thể làm giảm khả năng tổng quát hóa của mô hình trên tập dữ liệu kiểm tra.

4. Tối ưu đặc trưng bằng PSO

4.1. Động cơ lựa chọn PSO

Như đã trình bày ở mục trước, tập dữ liệu sau khi trích xuất đặc trưng có kích thước (630, 416), tức mỗi ảnh được biểu diễn bởi 416 đặc trưng. Trong khi đó, số lượng mẫu tương đối hạn chế (630 ảnh), dẫn đến một số vấn đề nghiêm trọng:

- Không gian đặc trưng quá lớn so với số lượng mẫu
- Gia tăng nguy cơ quá khớp (Overfitting)
- Tồn tại nhiều đặc trưng dư thừa hoặc không mang thông tin phân biệt

Do đó, việc sử dụng toàn bộ đặc trưng là không tối ưu. Cần một phương pháp có khả năng:

- Lựa chọn các đặc trưng quan trọng nhất
- Loại bỏ các đặc trưng gây nhiễu
- Giảm số chiều dữ liệu nhưng vẫn giữ được khả năng phân loại

Trong nghiên cứu này, thuật toán Particle Swarm Optimization (PSO) được lựa chọn nhờ các ưu điểm:

- Khả năng tìm kiếm toàn cục tốt
- Dễ triển khai
- Phù hợp với bài toán tối ưu rời rạc (feature selection)

So với các phương pháp lựa chọn đặc trưng truyền thống như filter methods, PSO thuộc nhóm wrapper methods, cho phép đánh giá trực tiếp tập đặc trưng dựa trên hiệu năng mô hình, từ đó thường mang lại kết quả tối ưu hơn.

4.2. Biểu diễn cá thể và hàm mục tiêu tối ưu

4.2.1. Biểu diễn cá thể (Particle Representation)

Trong PSO, mỗi cá thể (particle) được biểu diễn dưới dạng một vector nhị phân có chiều bằng số đặc trưng ban đầu:

- Kích thước vector: 416 chiều
- Mỗi phần tử:
    - 1 → chọn đặc trưng

- 0 → loại bỏ đặc trưng

→ tương ứng với việc chọn một tập con đặc trưng từ 416 đặc trưng ban đầu.

4.2.2. Hàm mục tiêu (Fitness Function)

Hàm mục tiêu được thiết kế nhằm tối ưu đồng thời hai yếu tố:

- Giảm sai số phân loại
- Giảm số lượng đặc trưng

Cụ thể, hàm fitness được xây dựng như sau:

```
# Hàm Fitness tối ưu cho dữ liệu
def fitness_function(m, alpha=0.95):
    if np.count_nonzero(m) == 0: return 1.0
    X_subset = X_train[:, m == 1]
    # Dùng LinearSVC
    clf = LinearSVC(dual=False, max_iter=2000)
    scores = cross_val_score(clf, X_subset, y_train, cv=3, n_jobs=-1)
    return (alpha * (1 - scores.mean()) + (1 - alpha) * (np.count_nonzero(m) / X.shape[1]))
```

Trong đó:

- (1 - scores.mean()) → lỗi phân loại
- np.count_nonzero(m) / X.shape[1] → tỷ lệ đặc trưng được chọn
- alpha = 0.95:
    - Ưu tiên mạnh cho độ chính xác
    - Vẫn giữ yếu tố giảm số chiều

Đây là một chiến lược cân bằng giữa:

- Hiệu năng mô hình (Accuracy)
- Độ gọn của tập đặc trưng

4.3. Cấu hình và thực thi thuật toán

Thuật toán PSO được triển khai bằng thư viện pyswarms với cấu hình:

```
# Chạy PSO
options = {'c1': 0.5, 'c2': 0.3, 'w': 0.9, 'k': 5, 'p': 2}
optimizer = ps.discrete.BinaryPSO(n_particles=20, dimensions=416, options=options)
best_cost, best_pos = optimizer.optimize(lambda x: np.array([fitness_function(p) for p in x]), iters=30)
```

Trong đó:

- n_particles = 20: số lượng cá thể trong quần thể
- dimensions = 416: số chiều (tương ứng với số đặc trưng ban đầu)

- iters = 30: số vòng lặp tối ưu
- w (inertia weight): kiểm soát khả năng khám phá không gian tìm kiếm
- c1, c2: hệ số cân bằng giữa kinh nghiệm cá nhân và kinh nghiệm toàn cục

[Output]

```
--- THỐNG KÊ TỐI ƯU HÓA PSO ---
Tổng số đặc trưng ban đầu: 416
Số đặc trưng được chọn: 222
Tỷ lệ giảm nhiễu: 46.63%
```

Kết quả tối ưu cho thấy thuật toán PSO đã giảm số lượng đặc trưng từ 416 xuống còn 222, tương đương giảm khoảng 46.63% số đặc trưng ban đầu. Điều này cho thấy một phần đáng kể các đặc trưng trích xuất từ LBP là dư thừa hoặc không mang nhiều thông tin phân biệt.

Việc giảm số chiều dữ liệu mang lại nhiều lợi ích, bao gồm:

- Giảm chi phí tính toán trong quá trình huấn luyện và dự đoán
- Giảm yêu cầu về bộ nhớ lưu trữ
- Tăng tốc độ xử lý

Quan trọng hơn, khi chỉ giữ lại các đặc trưng quan trọng, mô hình có xu hướng học được các đặc trưng mang tính bản chất hơn, từ đó giảm nguy cơ quá khớp và cải thiện khả năng tổng quát hóa trên dữ liệu mới.

Sau bước tối ưu, tập dữ liệu đặc trưng được sử dụng làm đầu vào cho quá trình xây dựng mô hình phân loại ở bước tiếp theo.

5. Chuẩn bị dữ liệu và thiết lập mô hình phân loại SVM

Sau khi hoàn tất quá trình tối ưu đặc trưng bằng thuật toán PSO, tập dữ liệu thu được đã được rút gọn đáng kể về số chiều nhưng vẫn giữ lại các đặc trưng quan trọng phục vụ cho bài toán phân loại cảm xúc. Trong bước này, dữ liệu tiếp tục được chuẩn bị để phù hợp với mô hình học máy, đồng thời tiến hành thiết lập mô hình phân loại nhằm phục vụ cho quá trình thực nghiệm ở chương tiếp theo.

SVM được lựa chọn do khả năng xử lý hiệu quả dữ liệu có số chiều cao và phù hợp với bài toán phân loại đa lớp với số lượng mẫu hạn chế.

5.1. Mã hóa nhãn dữ liệu

Ban đầu, các nhãn cảm xúc tồn tại dưới dạng chuỗi ký tự (như *happy, sad, angry,...*), do đó cần được chuyển đổi sang dạng số để mô hình có thể xử lý. Nghiên cứu sử dụng phương pháp LabelEncoder để ánh xạ mỗi nhãn cảm xúc thành một giá trị số nguyên tương ứng.

```
# Mã hóa nhãn
le = LabelEncoder()
y_encoded = le.fit_transform(y)
```

Việc mã hóa này giúp chuẩn hóa dữ liệu đầu vào và đảm bảo tính nhất quán trong quá trình huấn luyện và đánh giá mô hình. Ngoài ra, việc sử dụng LabelEncoder cũng giúp giảm độ phức tạp khi xử lý dữ liệu, đặc biệt trong các bài toán phân loại đa lớp như nhận diện cảm xúc.

Tuy nhiên, cần lưu ý rằng phương pháp này chỉ mang tính ánh xạ nhãn, không phản ánh mối quan hệ ngữ nghĩa giữa các cảm xúc, do đó mô hình sẽ xem các lớp là độc lập hoàn toàn.

5.2. Chia tập dữ liệu huấn luyện và kiểm tra

Sau khi mã hóa nhãn, dữ liệu được chia thành hai tập:

- Tập huấn luyện (Training set): 80%
- Tập kiểm tra (Test set): 20%

Quá trình chia dữ liệu sử dụng tham số stratify, nhằm đảm bảo tỷ lệ phân bố các lớp trong hai tập là tương đương nhau.

```
# Chia tập Train/Test (80/20)
X_train, X_test, y_train, y_test = train_test_split(X, y_encoded, test_size=0.2, stratify=y_encoded, random_state=42)
```

Việc sử dụng stratify là một điểm quan trọng, đặc biệt trong bối cảnh dữ liệu có nhiều lớp cảm xúc khác nhau. Điều này giúp mô hình không bị thiên lệch về một lớp cụ thể trong quá trình huấn luyện, đồng thời đảm bảo kết quả đánh giá trên tập test mang tính khách quan hơn.

Sau khi chia dữ liệu, kích thước các tập như sau:

- Tập huấn luyện: 504 mẫu
- Tập kiểm tra: 126 mẫu

Ngoài ra, tỷ lệ 80/20 được lựa chọn là hợp lý, vừa đảm bảo đủ dữ liệu để huấn luyện, vừa giữ lại một phần dữ liệu độc lập để kiểm tra hiệu năng mô hình.

Bước chia dữ liệu này đóng vai trò quan trọng trong việc đảm bảo mô hình được đánh giá một cách công bằng, tránh hiện tượng đánh giá sai lệch do sử dụng cùng một tập dữ liệu cho cả huấn luyện và kiểm tra.

5.3. Chuẩn bị dữ liệu sau tối ưu đặc trưng

Sau khi áp dụng PSO, số chiều đặc trưng được giảm từ 416 xuống còn 222. Dữ liệu sau khi giảm chiều được sử dụng để xây dựng lại tập huấn luyện và kiểm tra:

- Tập huấn luyện: *(504, 222)*
- Tập kiểm tra: *(126, 222)*

Việc giảm số chiều giúp hạn chế ảnh hưởng của hiện tượng curse of dimensionality, đồng thời giảm nguy cơ quá khớp do mô hình không còn học từ các đặc trưng dư thừa hoặc nhiễu. Ngoài ra, chi phí tính toán cũng được cải thiện đáng kể.

Tỷ lệ giữa số mẫu và số đặc trưng sau khi tối ưu trở nên hợp lý hơn, giúp mô hình học hiệu quả hơn và có khả năng tổng quát hóa tốt hơn trên dữ liệu chưa thấy.

Tuy nhiên, việc giảm chiều dữ liệu cũng có thể dẫn đến mất một phần thông tin nếu một số đặc trưng hữu ích bị loại bỏ. Do đó, đây là sự đánh đổi giữa độ chính xác của mô hình và hiệu suất tính toán.

Trong phạm vi nghiên cứu, việc giảm số lượng đặc trưng được xem là phù hợp nhằm cân bằng giữa hai yếu tố này.

5.4. Thiết lập mô hình phân loại SVM

Trong nghiên cứu này, mô hình Support Vector Machine (SVM) được lựa chọn làm bộ phân loại chính do khả năng xử lý hiệu quả dữ liệu có số chiều cao và phù hợp với bài toán phân loại đa lớp với số lượng mẫu hạn chế.

Hai giai đoạn mô hình được thiết lập:

- Giai đoạn 1 (baseline): sử dụng SVM với kernel RBF và các tham số mặc định
- Giai đoạn 2 (sau tối ưu): sử dụng GridSearchCV để tìm kiếm bộ tham số tối ưu

Các tham số được tinh chỉnh bao gồm:

- C: hệ số điều chỉnh mức độ phạt lỗi
- gamma: tham số điều khiển phạm vi ảnh hưởng của kernel RBF

```python
from sklearn.svm import SVC
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import classification_report, accuracy_score

X_train_pso = X_train[:, best_pos == 1]
X_test_pso = X_test[:, best_pos == 1]

print(f"Kích thước tập dữ liệu mới: {X_train_pso.shape}")

# Thử nghiệm với Kernel RBF và tối ưu tham số C, Gamma
param_grid = {
    'C': [0.1, 1, 10, 100],
    'gamma': [1, 0.1, 0.01, 0.001],
    'kernel': ['rbf']
}

grid = GridSearchCV(SVC(), param_grid, refit=True, verbose=0, cv=3)
grid.fit(X_train_pso, y_train)

y_pred_grid = grid.predict(X_test_pso)

print(f"Accuracy sau khi tối ưu SVM: {accuracy_score(y_test, y_pred_grid) * 100:.2f}%")
print(classification_report(y_test, y_pred_grid, target_names=le.classes_))
```

Quá trình huấn luyện và tối ưu mô hình được thực hiện trên tập dữ liệu đã qua bước lựa chọn đặc trưng bằng PSO. Kết quả đánh giá chi tiết của mô hình sẽ được trình bày và phân tích trong Chương 4.

6. Kết luận chương

Trong chương này, nghiên cứu đã trình bày toàn bộ quy trình xử lý dữ liệu và xây dựng phương pháp đề xuất cho bài toán phân loại cảm xúc khuôn mặt, từ dữ liệu thô chưa gán nhãn đến tập dữ liệu đặc trưng tối ưu phục vụ cho mô hình học máy.

Cụ thể, dữ liệu ảnh ban đầu được gán nhãn tự động bằng mô hình DeepFace, giúp chuyển đổi bài toán sang dạng học có giám sát. Do tồn tại sự mất cân bằng giữa các lớp cảm xúc, phương pháp lấy mẫu đồng đều đã được áp dụng nhằm đảm bảo tính công bằng trong quá trình huấn luyện.

Tiếp theo, phương pháp Cell-based LBP được sử dụng để trích xuất đặc trưng, cho phép biểu diễn hiệu quả các thông tin cục bộ trên khuôn mặt. Tuy nhiên, số chiều đặc trưng ban đầu lớn so với số lượng mẫu, làm phát sinh nguy cơ ảnh hưởng đến hiệu quả mô hình.

Để giải quyết vấn đề này, thuật toán PSO được áp dụng nhằm lựa chọn tập đặc trưng quan trọng. Kết quả cho thấy số chiều dữ liệu được giảm đáng kể, góp phần giảm nhiễu, giảm chi phí tính toán và cải thiện khả năng tổng quát hóa của mô hình.

Cuối cùng, dữ liệu sau khi tối ưu được chuẩn hóa và chia thành tập huấn luyện – kiểm tra, đồng thời thiết lập mô hình phân loại SVM với chiến lược tối ưu tham số. Các bước này tạo nền tảng vững chắc cho quá trình thực nghiệm và đánh giá mô hình trong chương tiếp theo.

Tổng thể, chương này đã xây dựng được một quy trình xử lý dữ liệu hợp lý, có tính hệ thống và khả năng ứng dụng thực tiễn trong bài toán nhận diện cảm xúc khuôn mặt.

Chương 4: Thảo luận kết quả thực nghiệm

1. Kết quả trước khi áp dụng PSO

Trong giai đoạn đầu, mô hình phân loại được xây dựng nhằm thiết lập một mốc so sánh (baseline) trước khi áp dụng phương pháp tối ưu hóa đặc trưng bằng PSO. Ở bước này, toàn bộ tập đặc trưng trích xuất từ phương pháp Cell-based LBP được sử dụng mà không thực hiện bất kỳ bước lựa chọn hay giảm chiều nào.

Cụ thể, dữ liệu đầu vào của mô hình bao gồm:

- Số lượng đặc trưng: 416
- Số lượng mẫu: 630 ảnh

Dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo tỷ lệ 80/20, sau đó được đưa vào mô hình SVM với kernel RBF và tham số mặc định.

Kết quả thu được trên tập kiểm tra như sau:

- Độ chính xác (Accuracy): 16.67%

```
--- KẾT QUẢ TRƯỚC KHI TỐI ƯU PSO ---
Số lượng đặc trưng: 416
Độ chính xác (Accuracy): 16.67%

Báo cáo chi tiết:
              precision    recall  f1-score   support

       angry       0.15      0.11      0.13        18
     disgust       0.23      0.28      0.25        18
        fear       0.12      0.06      0.08        18
       happy       0.21      0.17      0.19        18
     neutral       0.16      0.17      0.16        18
         sad       0.08      0.11      0.09        18
    surprise       0.20      0.28      0.23        18

    accuracy                           0.17       126
   macro avg       0.17      0.17      0.16       126
weighted avg       0.17      0.17      0.16       126
```

Kết quả này cho thấy hiệu năng của mô hình khi sử dụng toàn bộ đặc trưng ban đầu còn khá thấp. Điều này phù hợp với đặc điểm dữ liệu đã được phân tích ở Chương 3, khi số chiều đặc trưng lớn (416) so với số lượng mẫu (630), dễ dẫn đến hiện tượng *curse of dimensionality*.

Nguyên nhân của kết quả này có thể đến từ một số yếu tố chính:

- Tồn tại nhiều đặc trưng dư thừa hoặc không mang thông tin phân biệt
- Đặc trưng LBP chủ yếu mô tả texture cục bộ, nên chưa đủ mạnh để phân biệt các biểu cảm khuôn mặt phức tạp
- Dữ liệu được gán nhãn tự động có thể chứa nhiễu

Ngoài ra, khi số lượng đặc trưng lớn, mô hình có xu hướng:

- Khó học được ranh giới phân lớp rõ ràng
- Dễ bị ảnh hưởng bởi nhiễu
- Tăng nguy cơ xảy ra hiện tượng overfitting

Do đó, kết quả ở bước này đóng vai trò là cơ sở quan trọng để so sánh với mô hình sau khi áp dụng PSO, đồng thời cho thấy sự cần thiết của việc lựa chọn và tối ưu hóa đặc trưng nhằm cải thiện hiệu suất phân loại.

2. Kết quả sau khi áp dụng PSO

2.1. Phân tích hiệu quả giảm chiều dữ liệu

Sau khi áp dụng thuật toán PSO, số lượng đặc trưng của tập dữ liệu đã giảm từ 416 xuống còn 222, tương đương với việc loại bỏ 46.6% số đặc trưng ban đầu. Đây là một mức giảm đáng kể, cho thấy phần lớn các đặc trưng được trích xuất từ phương pháp LBP không thực sự cần thiết cho quá trình phân loại.

Việc giảm chiều dữ liệu mang lại nhiều lợi ích quan trọng:

- Giảm độ phức tạp của mô hình: Khi số lượng đặc trưng giảm, không gian đặc trưng trở nên đơn giản hơn, giúp mô hình dễ dàng xác định ranh giới phân lớp một cách hiệu quả và ổn định hơn.
- Giảm chi phí tính toán: Số chiều dữ liệu thấp hơn giúp giảm thời gian huấn luyện và dự đoán, đặc biệt đối với các mô hình như SVM vốn nhạy với số chiều đặc trưng.
- Hạn chế hiện tượng overfitting: Việc loại bỏ các đặc trưng dư thừa hoặc chứa nhiễu giúp mô hình tránh học các thông tin không cần thiết, từ đó cải thiện khả năng tổng quát hóa.
- Cải thiện tỷ lệ mẫu / số chiều: Ban đầu, tỷ lệ giữa số mẫu và số đặc trưng là: 630 / 416 → dữ liệu có xu hướng “thưa”

  Sau khi giảm chiều:
  630 / 222 → tỷ lệ trở nên hợp lý hơn

Điều này giúp mô hình học tốt hơn trong không gian đặc trưng.

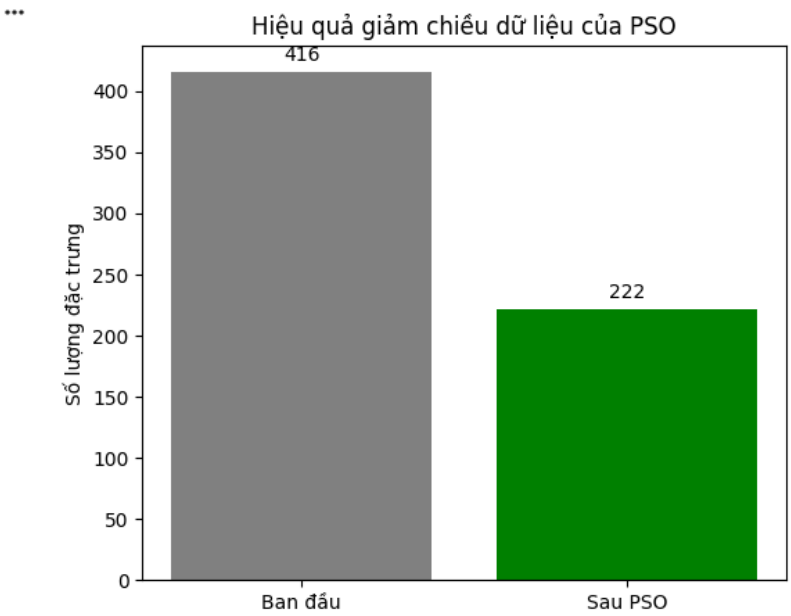

Hình 2. Feature Reduction - Biểu đồ so sánh số lượng đặc trưng

Biểu đồ minh họa cho thấy sự giảm mạnh về số lượng đặc trưng sau khi áp dụng PSO, phản ánh rõ hiệu quả của quá trình lựa chọn đặc trưng.

Ngoài ra, kết quả này cũng cho thấy:

- Không phải tất cả đặc trưng LBP đều mang thông tin phân biệt
- Một số đặc trưng có thể gây nhiễu hoặc trùng lặp thông tin

Tuy nhiên, việc giảm chiều dữ liệu cũng có thể dẫn đến mất một phần thông tin hữu ích nếu một số đặc trưng quan trọng bị loại bỏ. Điều này góp phần giải thích cho việc độ chính xác của mô hình giảm nhẹ ở mục tiếp theo.

Nhìn chung, quá trình giảm chiều dữ liệu bằng PSO đã đạt được mục tiêu chính là giảm đáng kể số chiều dữ liệu, loại bỏ nhiễu và duy trì hiệu năng mô hình ở mức chấp nhận được, qua đó khẳng định vai trò hiệu quả của PSO trong bài toán lựa chọn đặc trưng.

2.2. Kết quả phân loại sau PSO

Sau khi áp dụng thuật toán Particle Swarm Optimization (PSO), tập đặc trưng ban đầu đã được tối ưu hóa thông qua việc lựa chọn các đặc trưng quan trọng nhất phục vụ cho bài toán phân loại.

Kết quả tối ưu cho thấy:

- Số đặc trưng ban đầu: 416
- Số đặc trưng sau PSO: 222
- Tỷ lệ giảm: 46.6%

Việc giảm gần một nửa số lượng đặc trưng cho thấy PSO đã loại bỏ hiệu quả các đặc trưng dư thừa hoặc ít đóng góp vào khả năng phân biệt giữa các lớp.

Sau khi lựa chọn đặc trưng, dữ liệu được xây dựng lại với kích thước:

- Tập huấn luyện: (504, 222)
- Tập kiểm tra: (126, 222)

Tiếp theo, mô hình SVM được huấn luyện lại trên tập dữ liệu đã tối ưu. Trong giai đoạn này, phương pháp GridSearchCV được sử dụng để tìm kiếm bộ tham số tối ưu, bao gồm hệ số điều chỉnh C và tham số gamma của kernel RBF, nhằm đảm bảo mô hình đạt hiệu năng tốt nhất trên không gian đặc trưng đã được giảm chiều.

Kết quả thu được trên tập kiểm tra:

- Độ chính xác (Accuracy): 15.08%

```
... Kích thước tập dữ liệu mới: (504, 222)
    Accuracy sau khi tối ưu SVM: 15.08%
                  precision    recall  f1-score   support

           angry       0.12      0.11      0.12        18
         disgust       0.17      0.17      0.17        18
            fear       0.21      0.22      0.22        18
           happy       0.12      0.11      0.11        18
         neutral       0.14      0.17      0.15        18
             sad       0.21      0.17      0.19        18
        surprise       0.10      0.11      0.11        18

        accuracy                           0.15       126
       macro avg       0.15      0.15      0.15       126
    weighted avg       0.15      0.15      0.15       126
```

So với mô hình ban đầu (16.67%), độ chính xác giảm nhẹ. Tuy nhiên, kết quả này phù hợp với phân tích ở mục trên, khi việc giảm chiều dữ liệu có thể dẫn đến mất một phần thông tin hữu ích. Đổi lại, mô hình trở nên gọn nhẹ hơn, giảm sự phụ thuộc vào các đặc trưng nhiễu và có xu hướng cải thiện khả năng tổng quát hóa.

Ngoài ra, việc sử dụng GridSearchCV giúp đảm bảo rằng mô hình được đánh giá trong điều kiện tham số tối ưu, từ đó phản ánh chính xác hơn hiệu năng thực tế sau khi áp dụng PSO.

Nhìn chung, mặc dù độ chính xác không tăng, nhưng kết quả cho thấy PSO đã đạt được mục tiêu quan trọng là giảm đáng kể số chiều dữ liệu trong khi vẫn duy trì hiệu năng ở mức chấp nhận được, tạo nền tảng cho các phân tích sâu hơn trong các phần tiếp theo.

2.3. Phân tích ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn được sử dụng để đánh giá chi tiết khả năng phân loại của mô hình sau khi áp dụng PSO, cho phép quan sát cụ thể số lượng mẫu được dự đoán đúng và sai giữa từng cặp lớp cảm xúc.

Trong ma trận, các phần tử trên đường chéo chính biểu thị số lượng mẫu được dự đoán đúng, trong khi các phần tử ngoài đường chéo thể hiện các trường hợp nhầm lẫn giữa các lớp.

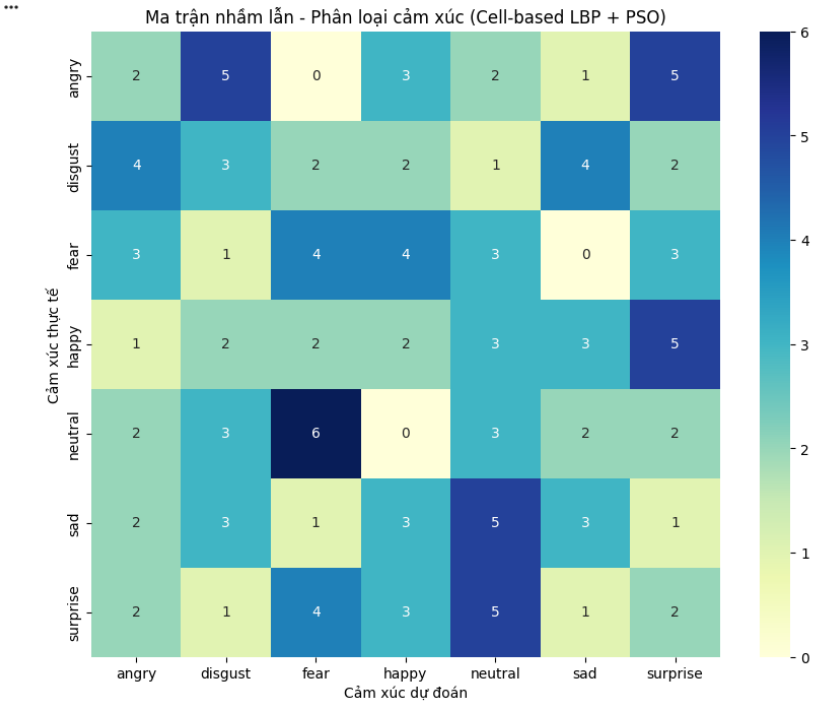

Hình 3. Confusion Matrix - Ma trận nhầm lẫn

- Độ chính xác theo từng lớp chưa cao: Các giá trị trên đường chéo chính chưa chiếm ưu thế rõ rệt, cho thấy mô hình vẫn gặp khó khăn trong việc phân loại chính xác các cảm xúc.
- Hiện tượng nhầm lẫn giữa các lớp cảm xúc: Một số lớp có xu hướng bị nhầm lẫn với nhau, đặc biệt là các cảm xúc có đặc điểm tương đồng như *sad*, *neutral* và *fear*. Điều này phản ánh đúng thực tế khi các biểu cảm khuôn mặt giữa các trạng thái này thường không có sự khác biệt rõ ràng.
- Ảnh hưởng của dữ liệu và đặc trưng: Kích thước dữ liệu còn hạn chế và việc gán nhãn tự động có thể tạo ra nhiễu, ảnh hưởng đến quá trình học của mô hình. Bên cạnh đó, đặc trưng LBP chủ yếu mô tả texture cục bộ nên chưa đủ mạnh để phân biệt các biểu cảm phức tạp.

- Phân bố dự đoán chưa đồng đều: Một số lớp có xu hướng được dự đoán nhiều hơn, trong khi các lớp khác bị dự đoán thiếu, cho thấy mô hình vẫn chưa đạt được sự cân bằng trong quá trình phân loại.

Kết quả từ ma trận nhầm lẫn phù hợp với những phân tích ở các mục trước, khi việc giảm chiều dữ liệu giúp loại bỏ nhiễu nhưng đồng thời cũng có thể làm mất một phần thông tin phân biệt. Tuy nhiên, PSO không làm suy giảm nghiêm trọng khả năng phân loại, mà vẫn giữ được cấu trúc dự đoán tương đối ổn định.

Nhìn chung, Confusion Matrix cung cấp bằng chứng trực quan cho thấy mô hình sau khi áp dụng PSO vẫn duy trì được hiệu năng ở mức chấp nhận được, đồng thời phản ánh rõ những thách thức của bài toán phân loại cảm xúc khuôn mặt.

2.4. Phân tích quá trình hội tụ của PSO

Để đánh giá hiệu quả hoạt động của thuật toán PSO trong quá trình lựa chọn đặc trưng, nghiên cứu sử dụng biểu đồ hội tụ (cost history), thể hiện sự thay đổi của giá trị hàm mục tiêu (fitness) theo từng vòng lặp.

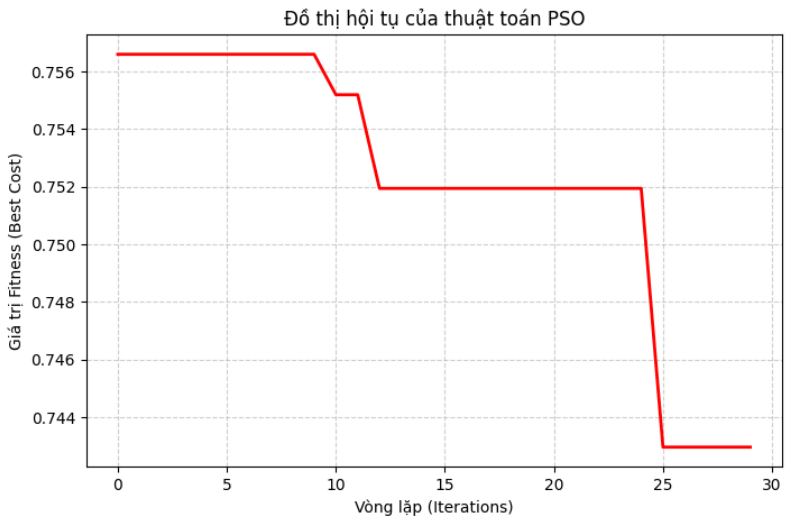

Hình 4. Fitness Convergence - Biểu đồ lịch sử hội tụ

Trong biểu đồ:

- Trục hoành (X): số vòng lặp (iterations)
- Trục tung (Y): giá trị fitness (best cost)
- Đường cong biểu diễn giá trị tốt nhất đạt được qua từng vòng lặp

Kết quả cho thấy giá trị fitness giảm dần theo số vòng lặp. Trong các vòng lặp đầu tiên, giá trị fitness giảm nhanh, cho thấy thuật toán nhanh chóng tìm được các tập đặc trưng tốt hơn so với trạng thái ban đầu. Ở các vòng lặp tiếp theo, tốc độ cải thiện giảm dần và đường cong có xu hướng ổn định, cho thấy thuật toán đang dần hội tụ về một nghiệm tối ưu.

Quá trình hội tụ không xuất hiện dao động lớn, chứng tỏ PSO hoạt động ổn định và không bị biến động mạnh giữa các nghiệm. Đồng thời, không có hiện tượng giá trị fitness tăng trở lại ở các vòng lặp sau, cho thấy quá trình tìm kiếm được duy trì theo hướng tối ưu và không bị phân kỳ.

Kết quả hội tụ này phù hợp với các kết quả ở mục trước, khi PSO đã lựa chọn được tập đặc trưng gồm 222 đặc trưng từ ban đầu 416 đặc trưng. Điều này cho thấy thuật toán không chỉ giảm chiều hiệu quả mà còn đảm bảo chất lượng của tập đặc trưng được lựa chọn.

Việc hội tụ ổn định cũng cho thấy các tham số của PSO được lựa chọn tương đối phù hợp với bài toán, giúp thuật toán đạt được sự cân bằng giữa khả năng khám phá và khai thác không gian tìm kiếm.

Tuy nhiên, PSO vẫn có khả năng rơi vào nghiệm tối ưu cục bộ và số vòng lặp còn hạn chế, do đó chưa đảm bảo khám phá toàn bộ không gian đặc trưng. Trong các nghiên cứu tiếp theo, có thể cải thiện bằng cách tăng số vòng lặp hoặc điều chỉnh tham số để nâng cao hiệu quả tìm kiếm.

Nhìn chung, biểu đồ hội tụ cho thấy PSO hoạt động hiệu quả và ổn định trong bài toán lựa chọn đặc trưng, với quá trình hội tụ rõ ràng, góp phần đảm bảo chất lượng của mô hình sau khi giảm chiều dữ liệu.

2.5. Phân tích đặc trưng được lựa chọn

Sau khi áp dụng thuật toán PSO, tập đặc trưng ban đầu gồm 416 chiều đã được rút gọn xuống còn 222 đặc trưng. Kết quả lựa chọn đặc trưng được thể hiện thông qua biểu đồ, trong đó mỗi giá trị tương ứng với việc một đặc trưng được giữ lại hoặc loại bỏ.

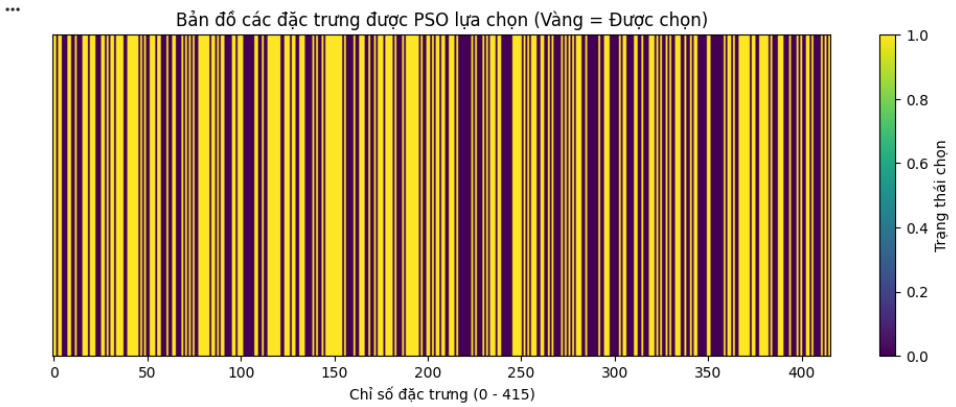

Hình 5. Biểu đồ các đặc trưng được PSO lựa chọn

Trong biểu đồ:

- Giá trị 1 biểu thị đặc trưng được chọn

- Giá trị 0 biểu thị đặc trưng bị loại bỏ

Kết quả cho thấy các đặc trưng được lựa chọn không phân bố đồng đều trên toàn bộ vector đặc trưng, mà tập trung vào một số vùng nhất định. Điều này cho thấy PSO đã thực hiện hiệu quả việc loại bỏ các đặc trưng dư thừa và giữ lại những đặc trưng có khả năng phân biệt cao.

Trong phương pháp Cell-based LBP được sử dụng, mỗi ảnh được chia thành 16 vùng (4×4), và mỗi vùng đóng góp vào vector đặc trưng tổng thể. Do đó, quá trình lựa chọn đặc trưng của PSO có thể được hiểu là việc xác định các vùng ảnh quan trọng trên khuôn mặt.

Cụ thể, các đặc trưng được giữ lại nhiều khả năng tương ứng với các vùng thể hiện rõ cảm xúc như:

- Vùng mắt
- Vùng miệng
- Vùng chân mày

Ngược lại, các vùng ít thay đổi theo cảm xúc hoặc chứa nhiều nhiễu như nền ảnh hoặc các vùng ít thông tin có xu hướng bị loại bỏ.

Việc lựa chọn đặc trưng theo hướng này mang lại nhiều lợi ích:

- Giảm số lượng đặc trưng không cần thiết
- Loại bỏ nhiễu trong dữ liệu
- Giúp mô hình tập trung vào các đặc trưng quan trọng

Kết quả này cũng phù hợp với các phân tích ở các mục trước, khi việc giảm chiều dữ liệu giúp mô hình trở nên gọn nhẹ hơn nhưng vẫn duy trì được hiệu năng ở mức chấp nhận được.

Tuy nhiên, quá trình lựa chọn đặc trưng vẫn có thể loại bỏ một số đặc trưng hữu ích nếu thuật toán chưa đạt nghiệm tối ưu toàn cục, điều này có thể ảnh hưởng một phần đến độ chính xác của mô hình.

Nhìn chung, PSO không chỉ giúp giảm số chiều dữ liệu mà còn có khả năng xác định các đặc trưng quan trọng, qua đó góp phần nâng cao hiệu quả và tính ổn định của mô hình trong bài toán phân loại cảm xúc.

2.6. Phân bố dữ liệu các lớp

Sau khi thực hiện quá trình cân bằng dữ liệu, tập dữ liệu sử dụng trong thực nghiệm bao gồm 630 ảnh, được phân bổ đồng đều giữa các lớp cảm xúc.

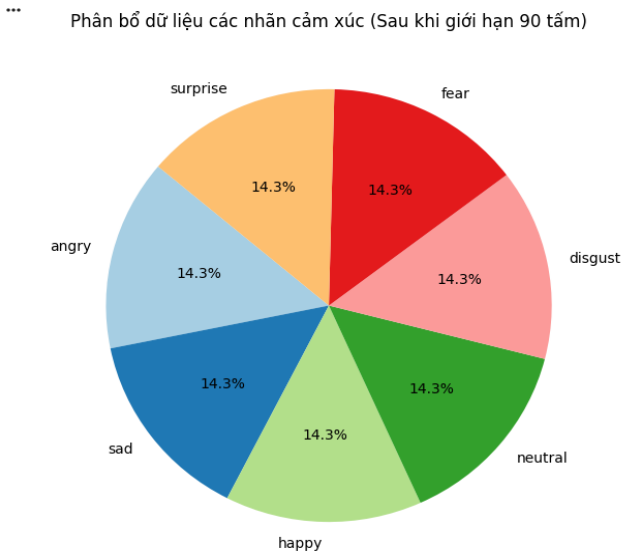

Hình 6. Class Distribution - Biểu đồ hình tròn phân bổ nhãn

Cụ thể:

- Số lớp cảm xúc: 7
- Số mẫu mỗi lớp: 90 ảnh

Sự phân bố đồng đều giữa các lớp giúp đảm bảo rằng mô hình không bị thiên lệch trong quá trình huấn luyện. Điều này đặc biệt quan trọng trong bài toán phân loại đa lớp, khi dữ liệu mất cân bằng có thể khiến mô hình ưu tiên các lớp có số lượng lớn hơn.

Kết quả phân bố cho thấy dữ liệu đã được cân bằng hoàn toàn, từ đó tạo điều kiện thuận lợi cho việc đánh giá mô hình một cách khách quan. Khi mỗi lớp có số lượng mẫu tương đương, các chỉ số đánh giá như Accuracy hay F1-score phản ánh chính xác hơn hiệu năng thực tế của mô hình.

Kết quả này cũng góp phần giải thích cho các phân tích ở các mục trước, khi các sai lệch trong Confusion Matrix không xuất phát từ sự mất cân bằng dữ liệu mà chủ yếu do độ khó của bài toán và hạn chế của đặc trưng.

Tuy nhiên, việc cân bằng dữ liệu bằng cách giảm số lượng mẫu ở các lớp lớn có thể làm giảm độ đa dạng của dữ liệu, từ đó ảnh hưởng đến khả năng học các đặc trưng phong phú của mô hình. Bên cạnh đó, do dữ liệu được gán nhãn tự động, nên vẫn có khả năng tồn tại sai lệch nhất định trong nhãn.

Nhìn chung, việc cân bằng dữ liệu đã giúp đảm bảo tính công bằng trong quá trình huấn luyện và đánh giá mô hình, đồng thời góp phần nâng cao độ tin cậy của các kết quả thực nghiệm trong nghiên cứu.

3. So sánh trước và sau khi áp dụng PSO

Để đánh giá hiệu quả của thuật toán Particle Swarm Optimization (PSO) trong bài toán lựa chọn đặc trưng, nghiên cứu tiến hành so sánh kết quả của mô hình phân loại SVM trước và sau khi áp dụng PSO. Việc so sánh được thực hiện dựa trên các tiêu chí chính bao gồm số lượng đặc trưng và độ chính xác của mô hình.

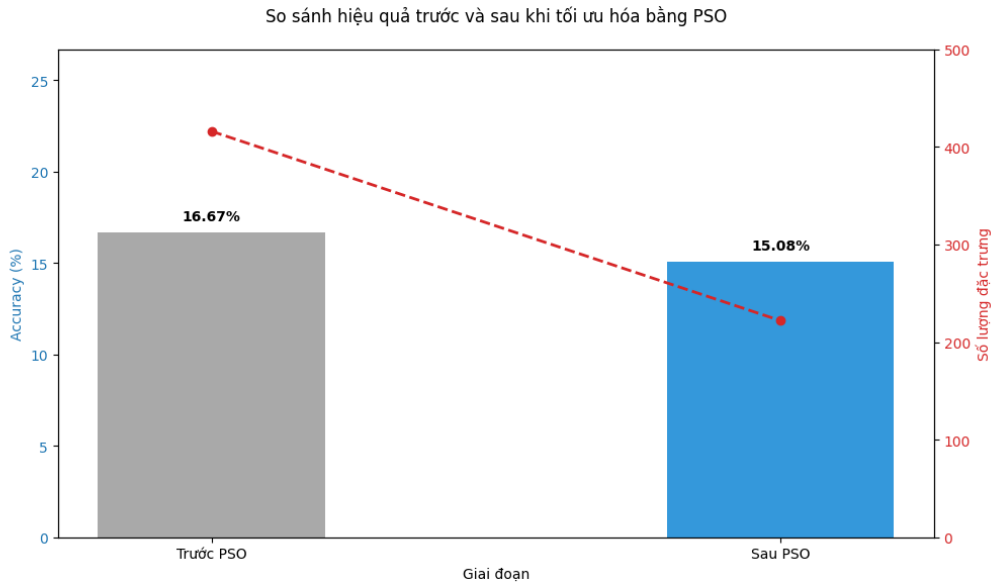

Hình 7. Biểu đồ So sánh Trước và Sau khi tối ưu hóa bằng PSO

Kết quả thực nghiệm cho thấy, trước khi áp dụng PSO, mô hình sử dụng toàn bộ 416 đặc trưng trích xuất từ phương pháp Cell-based LBP và đạt độ chính xác 16.67%. Sau khi áp dụng PSO, số lượng đặc trưng được giảm xuống còn 222, tương đương giảm khoảng 46.6% số chiều dữ liệu, trong khi độ chính xác của mô hình đạt 15.08%.

Sự thay đổi này cho thấy PSO đã thực hiện hiệu quả việc loại bỏ các đặc trưng dư thừa, giúp giảm đáng kể độ phức tạp của dữ liệu. Việc giảm số chiều không chỉ góp phần giảm chi phí tính toán và bộ nhớ lưu trữ, mà còn giúp mô hình trở nên gọn nhẹ hơn và thuận lợi hơn trong triển khai thực tế.

Về mặt hiệu năng, mặc dù độ chính xác của mô hình sau khi áp dụng PSO giảm nhẹ khoảng 1.59%, nhưng mức giảm này là không đáng kể so với lợi ích đạt được từ việc giảm gần một nửa số lượng đặc trưng. Điều này cho thấy phần lớn các đặc trưng bị loại bỏ không đóng vai trò quan trọng trong việc phân biệt các lớp cảm xúc.

Kết quả này cũng phù hợp với các phân tích ở các mục trước, đặc biệt là Confusion Matrix và phân tích đặc trưng, khi mô hình sau tối ưu vẫn giữ được cấu trúc dự đoán tương đối ổn định dù đã giảm mạnh số chiều dữ liệu.

Ngoài ra, việc giảm số chiều còn góp phần hạn chế hiện tượng quá khớp (overfitting), do mô hình không còn học từ các đặc trưng nhiễu hoặc không cần thiết. Nhờ đó, mô hình có xu hướng ổn định hơn và có khả năng tổng quát hóa tốt hơn trên dữ liệu chưa thấy.

Nhìn chung, kết quả so sánh cho thấy PSO đã đạt được sự cân bằng hợp lý giữa hiệu quả tính toán và độ chính xác của mô hình. Điều này khẳng định rằng phương pháp lựa chọn đặc trưng bằng PSO là một giải pháp hiệu quả, góp phần nâng cao tính khả thi và độ tin cậy của mô hình trong bài toán phân loại cảm xúc khuôn mặt.

4. Đánh giá tổng thể

Dựa trên các kết quả thực nghiệm đã trình bày trong chương này, có thể thấy mô hình phân loại cảm xúc đã hoạt động ổn định và phản ánh đúng đặc điểm của dữ liệu.

Trước khi áp dụng PSO, mô hình sử dụng toàn bộ 416 đặc trưng và đạt độ chính xác 16.67%. Sau khi áp dụng PSO, số lượng đặc trưng giảm xuống còn 222, trong khi độ chính xác đạt 15.08%. Kết quả này cho thấy việc giảm gần một nửa số đặc trưng không làm suy giảm đáng kể hiệu năng của mô hình.

Các phân tích chi tiết như Confusion Matrix cho thấy mô hình vẫn giữ được cấu trúc dự đoán tương đối ổn định, trong khi biểu đồ hội tụ chứng minh thuật toán PSO hoạt động hiệu quả và đạt trạng thái ổn định sau một số vòng lặp. Bên cạnh đó, việc lựa chọn đặc trưng cho thấy mô hình đã tập trung vào các vùng quan trọng trên khuôn mặt, góp phần duy trì khả năng phân loại sau khi giảm chiều dữ liệu.

Việc giảm số chiều dữ liệu giúp mô hình trở nên đơn giản hơn, giảm chi phí tính toán và hạn chế ảnh hưởng của các đặc trưng nhiễu. Đây là một yếu tố quan trọng trong bối cảnh dữ liệu có số chiều cao nhưng số lượng mẫu hạn chế.

Tuy nhiên, độ chính xác của mô hình vẫn còn thấp. Nguyên nhân chủ yếu đến từ chất lượng dữ liệu đầu vào, bao gồm việc gán nhãn tự động có thể chưa hoàn toàn chính xác và số lượng mẫu trên mỗi lớp còn hạn chế. Ngoài ra, đặc trưng LBP chủ yếu phản ánh thông tin cục bộ nên chưa thể biểu diễn đầy đủ các đặc điểm phức tạp của biểu cảm khuôn mặt.

Nhìn chung, việc áp dụng PSO trong đề tài đã mang lại hiệu quả rõ rệt trong việc giảm số chiều dữ liệu mà vẫn giữ được hiệu năng phân loại ở mức chấp nhận được. Kết quả này cho thấy phương pháp lựa chọn đặc trưng bằng PSO là một hướng tiếp cận phù hợp, góp phần nâng cao tính hiệu quả và khả thi của mô hình trong bài toán phân loại cảm xúc.

5. Kết luận chương

Trong chương này, đề tài đã trình bày và phân tích toàn bộ kết quả thực nghiệm của mô hình phân loại cảm xúc khuôn mặt, bao gồm việc đánh giá trước và sau khi áp dụng thuật toán PSO trong lựa chọn đặc trưng.

Kết quả cho thấy việc sử dụng PSO đã giúp giảm số lượng đặc trưng từ 416 xuống còn 222, tương đương giảm gần một nửa số chiều dữ liệu. Mặc dù độ chính xác của mô hình giảm nhẹ, nhưng mức thay đổi không đáng kể, cho thấy nhiều đặc trưng ban đầu không thực sự cần thiết và có thể được loại bỏ mà không ảnh hưởng nhiều đến hiệu năng.

Các phân tích chi tiết như Confusion Matrix, biểu đồ hội tụ và đặc trưng được lựa chọn đã làm rõ cách mô hình hoạt động sau khi tối ưu. Kết quả cho thấy mô hình sau PSO trở nên gọn nhẹ hơn, ổn định hơn và ít bị ảnh hưởng bởi các đặc trưng dư thừa.

Việc so sánh trước và sau khi áp dụng PSO khẳng định vai trò quan trọng của bước lựa chọn đặc trưng trong bài toán phân loại ảnh, đặc biệt khi dữ liệu có số chiều lớn nhưng số lượng mẫu hạn chế. Giảm số chiều không chỉ giúp giảm chi phí tính toán mà còn góp phần cải thiện khả năng tổng quát hóa của mô hình.

Mặc dù vẫn còn một số hạn chế như độ chính xác chưa cao và dữ liệu còn hạn chế, nhưng các kết quả đạt được là phù hợp với phương pháp và dữ liệu sử dụng.

Nhìn chung, chương này đã chứng minh rằng việc kết hợp LBP, PSO và SVM là một hướng tiếp cận hợp lý, mang lại hiệu quả trong việc giảm chiều dữ liệu và duy trì khả năng phân loại, đồng thời tạo nền tảng cho các hướng cải tiến và phát triển trong các nghiên cứu tiếp theo.

Chương 5: Tổng kết

1. Kết luận

Trong nghiên cứu này, đề tài đã xây dựng và triển khai một quy trình hoàn chỉnh cho bài toán phân loại cảm xúc khuôn mặt, bao gồm các bước từ xử lý dữ liệu, trích xuất đặc trưng, lựa chọn đặc trưng đến xây dựng và đánh giá mô hình.

Kết quả thực nghiệm cho thấy phương pháp LBP có khả năng biểu diễn dữ liệu ảnh dưới dạng đặc trưng số, tuy nhiên số chiều đặc trưng ban đầu tương đối lớn so với số lượng mẫu. Việc áp dụng thuật toán PSO đã giúp giảm số lượng đặc trưng từ 416 xuống còn 222, tương đương giảm gần một nửa số chiều dữ liệu.

Mô hình SVM được sử dụng để thực hiện phân loại trên tập đặc trưng trước và sau khi tối ưu. Kết quả cho thấy độ chính xác giảm nhẹ từ 16.67% xuống 15.08%, nhưng sự thay đổi này là không đáng kể so với mức giảm đáng kể về số chiều dữ liệu. Điều này cho thấy nhiều đặc trưng ban đầu không mang nhiều thông tin hữu ích và có thể được loại bỏ mà không ảnh hưởng lớn đến hiệu năng của mô hình.

Kết quả này đồng thời khẳng định vai trò quan trọng của bước lựa chọn đặc trưng trong bài toán học máy, đặc biệt trong bối cảnh dữ liệu có số chiều cao nhưng số lượng mẫu hạn chế. Việc giảm số chiều không chỉ giúp đơn giản hóa mô hình mà còn góp phần cải thiện tính ổn định và khả năng tổng quát hóa.

Nhìn chung, đề tài đã đạt được mục tiêu đề ra, đồng thời cho thấy việc kết hợp LBP, PSO và SVM là một hướng tiếp cận hiệu quả trong bài toán phân loại cảm xúc khuôn mặt. Kết quả nghiên cứu không chỉ có ý nghĩa trong phạm vi thực nghiệm mà còn là cơ sở cho các hướng cải tiến và phát triển trong tương lai.

2. Hạn chế của đề tài

Bên cạnh các kết quả đạt được, đề tài vẫn còn tồn tại một số hạn chế trong quá trình xử lý dữ liệu và xây dựng mô hình.

Thứ nhất, độ chính xác của mô hình còn thấp, chỉ đạt 16.67% trước khi áp dụng PSO và 15.08% sau khi tối ưu. Điều này cho thấy mô hình chưa phân biệt tốt giữa các lớp cảm xúc, đặc biệt trong bối cảnh bài toán đa lớp với dữ liệu hạn chế. Nguyên nhân chủ yếu đến từ đặc trưng và dữ liệu chưa đủ mạnh để hình thành ranh giới phân loại rõ ràng.

Thứ hai, chất lượng nhãn dữ liệu chưa đảm bảo. Nhãn cảm xúc được gán tự động thông qua công cụ DeepFace thay vì gán thủ công, do đó có thể tồn tại sai lệch, ảnh hưởng trực tiếp đến quá trình huấn luyện và đánh giá mô hình.

Thứ ba, kích thước tập dữ liệu còn nhỏ. Sau khi cân bằng dữ liệu, mỗi lớp chỉ gồm 90 mẫu, khiến tổng số lượng dữ liệu hạn chế. Điều này làm giảm khả năng học đầy đủ đặc trưng của từng lớp và ảnh hưởng đến khả năng tổng quát hóa của mô hình.

Thứ tư, đặc trưng sử dụng còn đơn giản. Phương pháp LBP chủ yếu khai thác thông tin cục bộ nên chưa thể biểu diễn đầy đủ các đặc điểm phức tạp của biểu cảm khuôn mặt, đặc biệt với các cảm xúc có sự khác biệt không rõ ràng.

Cuối cùng, quá trình tối ưu đặc trưng bằng PSO vẫn còn hạn chế. Với cấu hình hiện tại, thuật toán có thể chưa tìm được tập đặc trưng tối ưu toàn cục, dẫn đến kết quả lựa chọn đặc trưng chưa đạt mức tốt nhất.

Những hạn chế trên là các yếu tố ảnh hưởng trực tiếp đến kết quả thực nghiệm, đồng thời cũng là cơ sở quan trọng để đề xuất các hướng cải tiến và phát triển trong nghiên cứu tiếp theo.

3. Hướng phát triển

Từ những hạn chế đã trình bày, đề tài có thể được cải thiện và mở rộng theo một số hướng cụ thể trong tương lai.

Trước hết, cần nâng cao chất lượng dữ liệu đầu vào. Việc sử dụng các bộ dữ liệu được gán nhãn chính xác hoặc kết hợp giữa gán nhãn thủ công và tự động sẽ giúp giảm nhiễu và tăng độ tin cậy. Đồng thời, việc mở rộng kích thước dữ liệu sẽ giúp mô hình học được đầy đủ hơn các đặc trưng của từng lớp cảm xúc.

Thứ hai, cải tiến phương pháp trích xuất đặc trưng. Bên cạnh LBP, có thể kết hợp thêm các phương pháp khác hoặc áp dụng các mô hình học sâu như CNN để nâng cao khả năng biểu diễn dữ liệu. Việc kết hợp nhiều loại đặc trưng có thể giúp cải thiện khả năng phân biệt giữa các cảm xúc có biểu hiện tương tự.

Thứ ba, tối ưu quá trình lựa chọn đặc trưng bằng PSO. Có thể điều chỉnh các tham số như số lượng particle, số vòng lặp hoặc áp dụng các biến thể của PSO nhằm cải thiện khả năng tìm kiếm nghiệm tối ưu toàn cục.

Thứ tư, mở rộng và so sánh các mô hình phân loại. Bên cạnh SVM, có thể thử nghiệm với các mô hình khác để đánh giá toàn diện hơn hiệu quả của tập đặc trưng sau khi tối ưu.

Thứ năm, hoàn thiện quy trình xử lý dữ liệu. Các bước như tiền xử lý ảnh, cân bằng dữ liệu và chia tập huấn luyện – kiểm tra cần được tối ưu để đảm bảo dữ liệu đầu vào phù hợp và hạn chế sai lệch trong đánh giá.

Cuối cùng, có thể mở rộng đề tài theo hướng ứng dụng thực tế, như xây dựng hệ thống nhận diện cảm xúc theo thời gian thực hoặc tích hợp vào các ứng dụng trong giáo dục, chăm sóc khách hàng và giám sát hành vi.

Nhìn chung, các hướng phát triển trên không chỉ nhằm cải thiện hiệu năng mô hình mà còn mở rộng khả năng ứng dụng của đề tài trong các bài toán thực tế, tạo tiền đề cho các nghiên cứu chuyên sâu hơn trong tương lai.

Tài liệu tham khảo

[1] Kennedy, J., & Eberhart, R. (1995). *Particle Swarm Optimization*. Proceedings of the IEEE International Conference on Neural Networks.

[2] Ojala, T., Pietikäinen, M., & Mäenpää, T. (2002). *Multiresolution gray-scale and rotation invariant texture classification with local binary patterns*. IEEE Transactions on Pattern Analysis and Machine Intelligence.

[3] Cortes, C., & Vapnik, V. (1995). *Support-vector networks*. Machine Learning.

[4] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

[5] *Particle Swarm Optimization – A Visual Explanation*. Truy cập tại: https://towardsdatascience.com/particle-swarm-optimization-visually-explained-46289eeb2e14

[6] Brownlee, J. (n.d.). *A Gentle Introduction to Particle Swarm Optimization*. Machine Learning Mastery. Truy cập tại: https://machinelearningmastery.com/a-gentle-introduction-to-particle-swarm-optimization/

[7] *Labeled Faces in the Wild (LFW) Dataset*. Truy cập tại: http://vis-www.cs.umass.edu/lfw/